

StudyRadar

StudyRadar — ИИ-агент для сортировки учебных сообщений и контроля дедлайнов

Команда SuperPuper · группа ИУ5-31Б

МГТУ им. Н. Э. Баумана · кафедра ИУ5

Кейс-чемпионат по созданию ИИ-агентов · дисциплина «Архитектура АСОИУ»

2026

Состав команды

Все участники — группа ИУ5-31Б

ФИО	Группа	Роль в проекте
Синявский Станислав	ИУ5-31Б	Капитан; архитектура и оркестратор агента (LangGraph)
Теплицкий Кирилл	ИУ5-31Б	Интеграция с Telegram: бот, хаб, доска дедлайнов
Летуновский Артемий	ИУ5-31Б	Индексация и RAG: эмбеддинги, Chroma, гибридный поиск
Бабичев Александр	ИУ5-31Б	MCP-сервер и инструменты агента
Санина Анастасия	ИУ5-31Б	Промпты, датасет и оценка качества
Галюк Станислава	ИУ5-31Б	Интерфейс (Streamlit) и презентация

Постановка задачи

У студента 5+ учебных чатов — важное тонет во флуде

Проблема

- дедлайны, задания, переносы и отмены теряются среди мемов, «спасибо» и болтовни
- преподаватель пишет объявление серией коротких сообщений
- сроки — в свободной форме: «до пятницы», «через 1,5 недели», «к следующей паре»
- информация уточняется и меняется позже (аудитория, время, «можно» → «нельзя»)

Почему не поиск по ключевым словам

- слово есть, а смысла нет; смысл есть, а слова нет — нужен анализ по смыслу (LLM)

«физика — это боль»

Ключевые слова: «физика» → важное ❌

StudyRadar: шум — предмет упомянут, учебной информации нет ✅

«лабу перенесли на среду» (ответом)

Ключевые слова: предмет не найден ❌

StudyRadar: перенос защиты ЛР2 по электротехнике с пт 30.10 на ср 04.11 — по сообщению, на которое ответили; дедлайн обновлён, а не продублирован ✅

Что делает агент

Не чатбот «спроси — ответь», а автономный агент: реагирует на события сам

1. Читает учебные чаты

Telegram-бот: новые и отредактированные сообщения + история из JSON-экспорта

2. Понимает смысл

LLM решает: важно ли, предмет, категория, срок (от даты сообщения)

3. Раскладывает по темам

пересылает в тему предмета чата-хаба с пометкой агента

4. Ведёт доску дедлайнов

одно закреплённое сообщение, сортировка по сроку, правится при изменениях

5. Отслеживает изменения

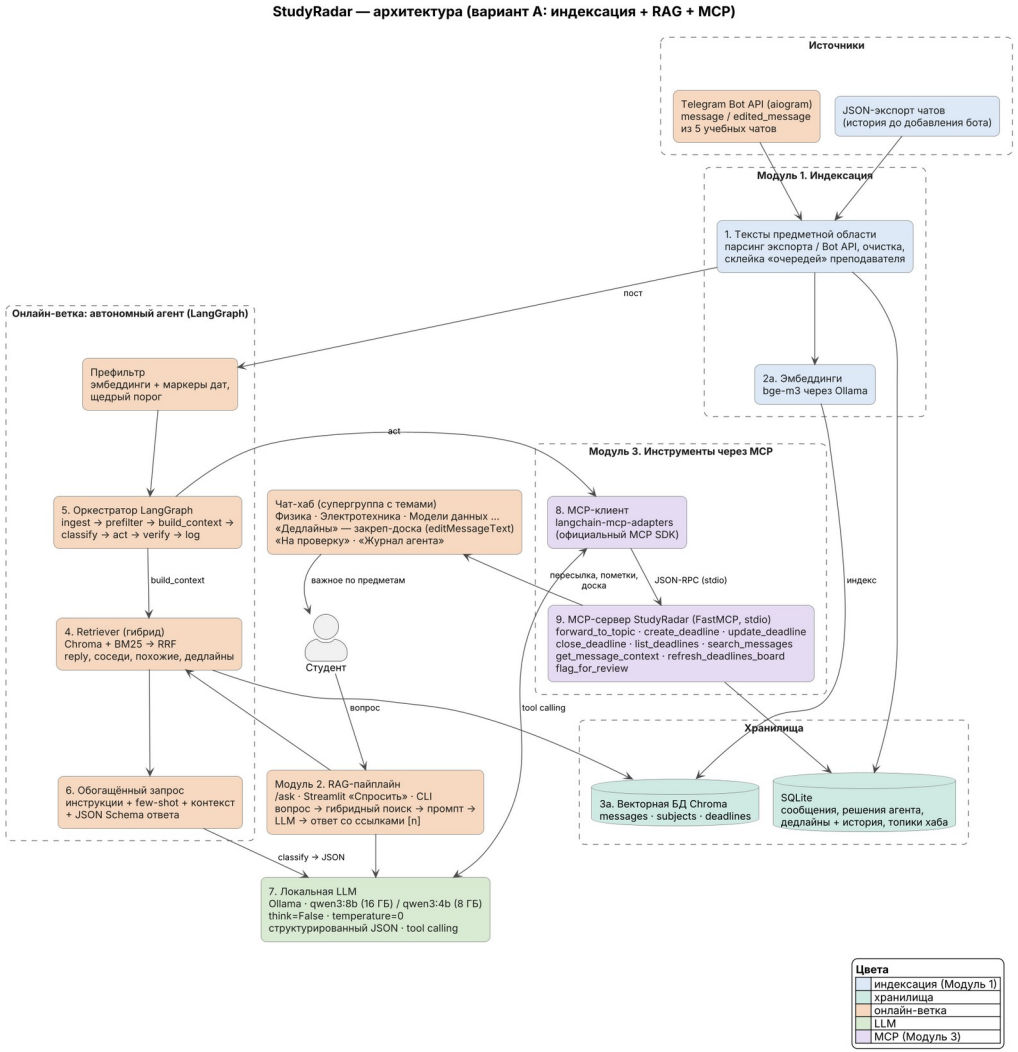
перенос, отмена, уточнение, редактирование → обновляет, а не дублирует

6. Отвечает на вопросы

/ask — ответ по переписке со ссылками на исходные сообщения (RAG)

Архитектура

Вариант A: индексация + RAG + инструменты через MCP



Модуль 1 · Индексация

сообщения и справочник предметов → bge-m3 → Chroma (messages, subjects, deadlines)

Модуль 2 · RAG-пайплайн

вопрос → гибридный поиск (Chroma + BM25, RRF) → обогащённый промпт → LLM → ответ со ссылками

Модуль 3 · Инструменты через MCP

LLM сама вызывает 9 инструментов MCP-сервера (FastMCP, stdio): пересылка, дедлайны, доска

Оркестратор LangGraph

ingest → prefilter → build_context → classify → act → verify → log

Три модуля варианта А в коде

Каждый модуль легко найти по имени папки

Модуль 1. Индексация

src/study_radar/index/

- парсер Telegram-экспорта: text строкой и массивом, rich_message, темы форума, edited, файлы
- склейка «очередей» преподавателя (≤ 5 мин)
- bge-m3 через Ollama → Chroma
- идемпотентно: id = пост

Модуль 2. RAG

src/study_radar/retrieval/hybrid.py

src/study_radar/agent/ask.py

- векторный поиск + BM25 → RRF
- фильтры: предмет, чат, даты
- промпт требует ссылки [n]; нет данных — «в переписке нет информации»

Модуль 3. MCP

src/study_radar/mcp_server/server.py

src/study_radar/agent/graph.py (узел act)

- FastMCP, stdio, 9 инструментов
- клиент: langchain-mcp-adapters
- LLM сама выбирает инструменты; 2 неудачные попытки → фолбэк через те же MCP-инструменты

Технологии

Всё работает локально на ноутбуке; облачные LLM не используются

Компонент	Выбор	Почему
LLM	Ollama + Qwen3 8B / 4B	локально; 16 ГБ RAM → 8B, 8 ГБ → 4B (одна строка в .env); tool calling, JSON
Эмбеддинги	bge-m3 (Ollama)	мультиязычная, хорошо понимает русский; тот же Ollama
Векторная БД	Chroma (persistent)	локально, без сервера, фильтры по метаданным
Retriever	Chroma + rank_bm25 → RRF	смысл + точные слова (номера ЛР, аудитории)
Оркестратор	LangGraph	явный граф узлов агента, условные переходы
MCP	FastMCP (stdio) + langchain-mcp-adapters	стандартный протокол инструментов
Telegram	aiogram 3 (бот)	без userbot — не рискуем личным аккаунтом
Хранилище	SQLite	дедлайны, история изменений, решения агента
Интерфейс	Streamlit + Typer CLI	дашборд для демо и трассировка агента

Ход разработки

Итерации: после каждой — рабочее состояние и зелёные тесты

1. MVP-ядро	2. Модули A	3. Обновления	4. Telegram	5. Интерфейс	6. Оценка	7. Документация
парсер экспорта, склейка очередей, SQLite, классификация, доска	Chroma, гибридный RAG, MCP-сервер, LangGraph + фолбэк	переносы, редактирования, дедупликация, история	бот на aiogram, темы хаба, закреп-доска, /ask	Streamlit: лента, хаб, дедлайны, трассировка	195 размеченных постов, бейзлайн по ключевым словам	README, схема, сценарий демо, презентация

Код покрыт тестами (pytest): парсер, даты, склейка, MCP через stdio, перенос/дубль/редактирование, фолбэк, RAG.

Для тестов без Ollama и Telegram — заглушки FakeLLM / HashEmbedder / FakeHub (только для проверки кода).

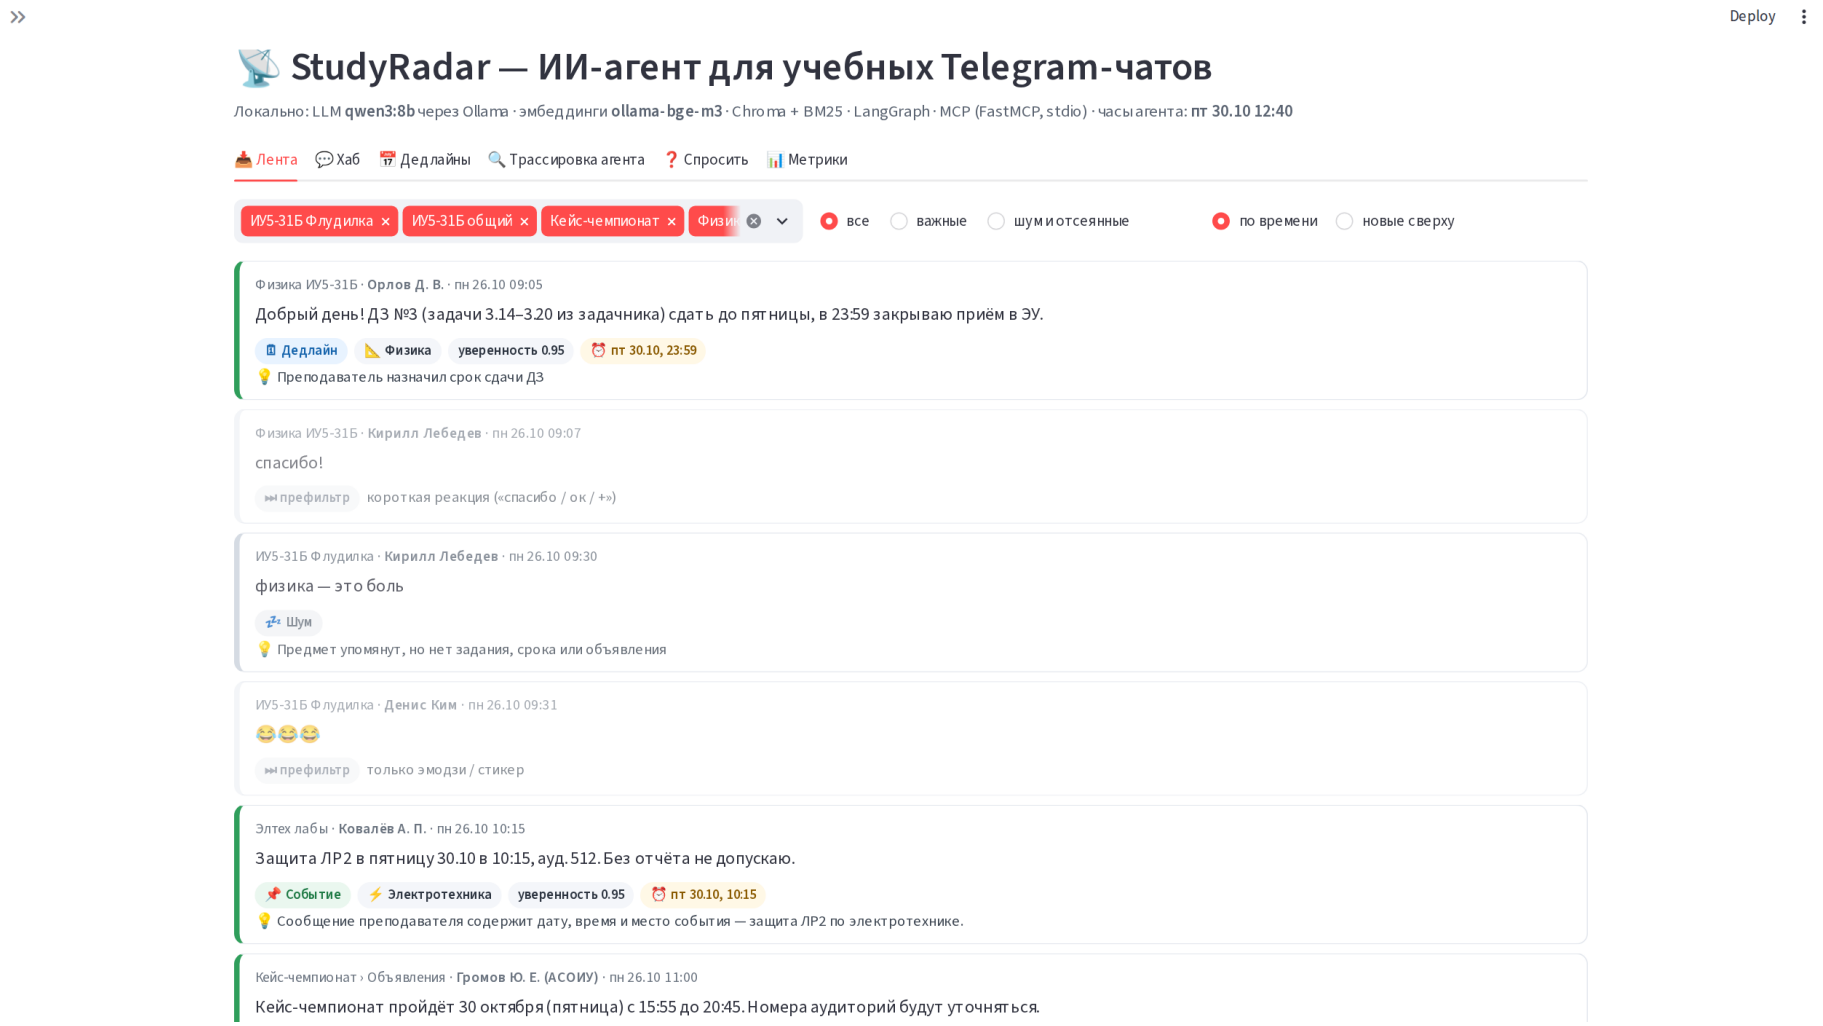
Трудности и решения

Из журнала разработки (docs/devlog.md)

Трудность	Решение
Преподаватель дробит объявление на 5–7 сообщений	склейка «очередей» (автор, тема, ≤ 5 мин); в боте — пауза 45 с
Сроки словами: «до пятницы», «1,5 недели»	расчёт от даты сообщения + перепроверка кодом и dateparser
«05.11» читалось как время 05:11, «16:00.» — не время	отдельный разбор дат и времени, тесты на каждый случай
«физ» находилось внутри «физру»	проверка целого слова и списка «ложных друзей» предмета
8B-модель может ошибиться в вызове инструмента (не тот, битые аргументы)	проверка плана, 2 попытки, детерминированный фолбэк через MCP
Telegram не умеет пересортировать сообщения	одно закреплённое сообщение-доска, editMessageText
Один дедлайн пишут в двух чатах	дедупликация: предмет + похожесть названия + дата + решение LLM
Бот не видит сообщения в группах	privacy mode → Disable в @BotFather, проверка в make doctor
Ollama в WSL не видела видеокарту и считала на CPU (минуты на сообщение)	обновили драйвер NVIDIA (536 → 621): qwen3:8b на 100% GPU, ~5 с на сообщение
api.telegram.org из WSL доступен только через VPN	прокси для бота: TELEGRAM_PROXY в .env (aiogram + aiohttp-socks)
WSL и VS Code отключались под нагрузкой	лимит памяти WSL, модели выгружаются через 5 мин простоя

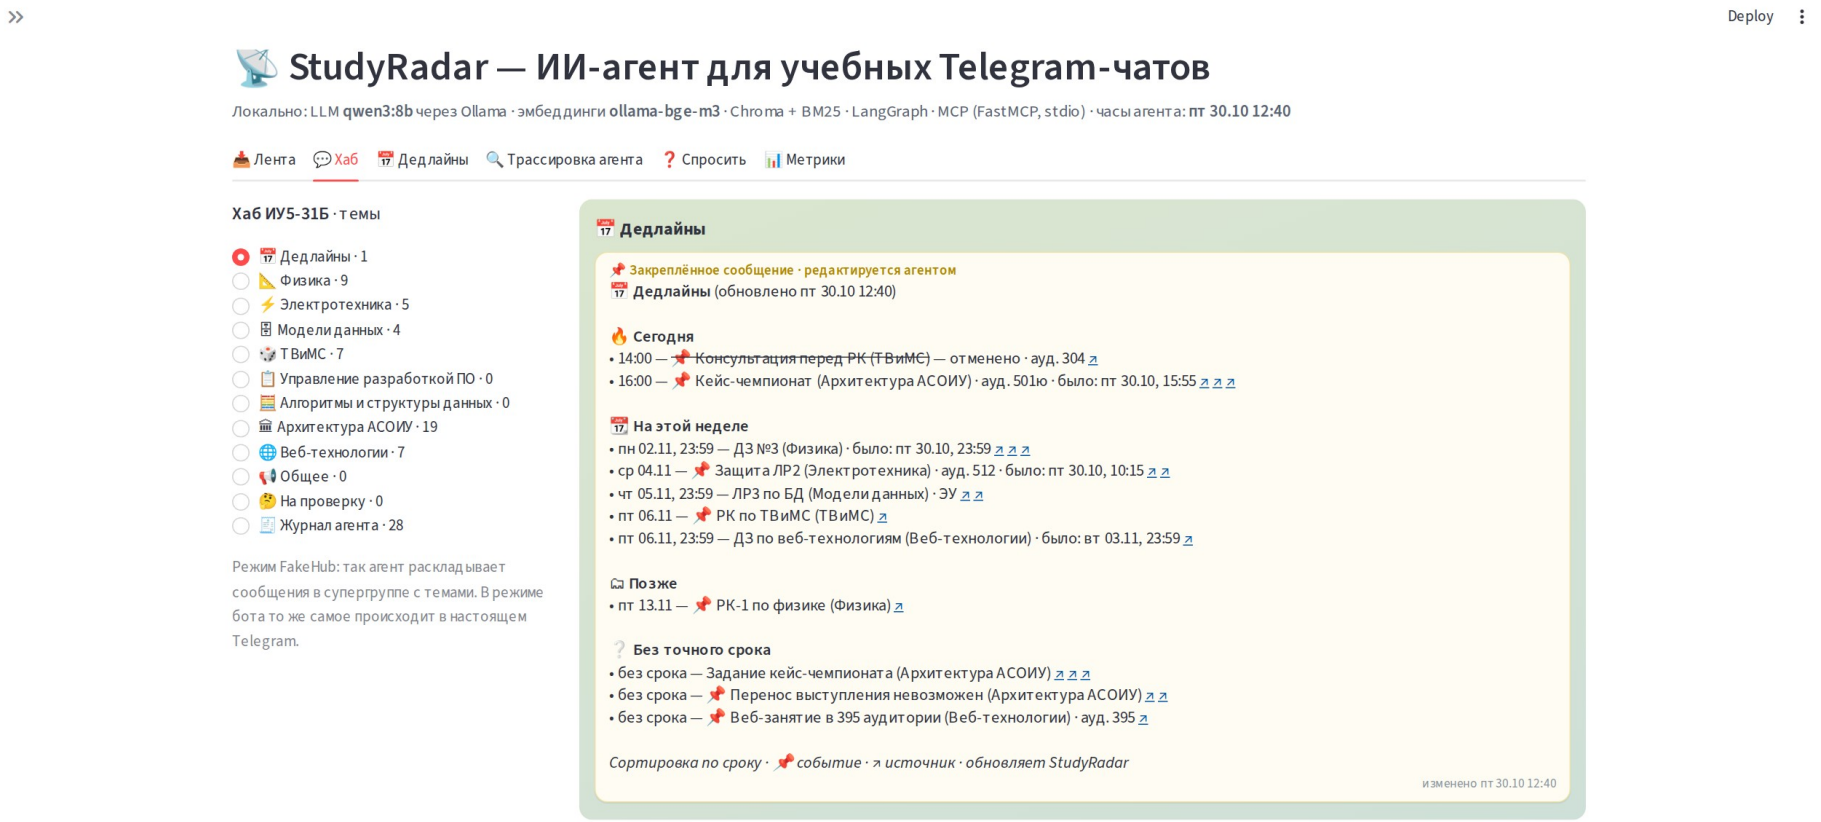
Экранная форма: лента решений

Каждое сообщение и решение агента: категория, предмет, уверенность, причина



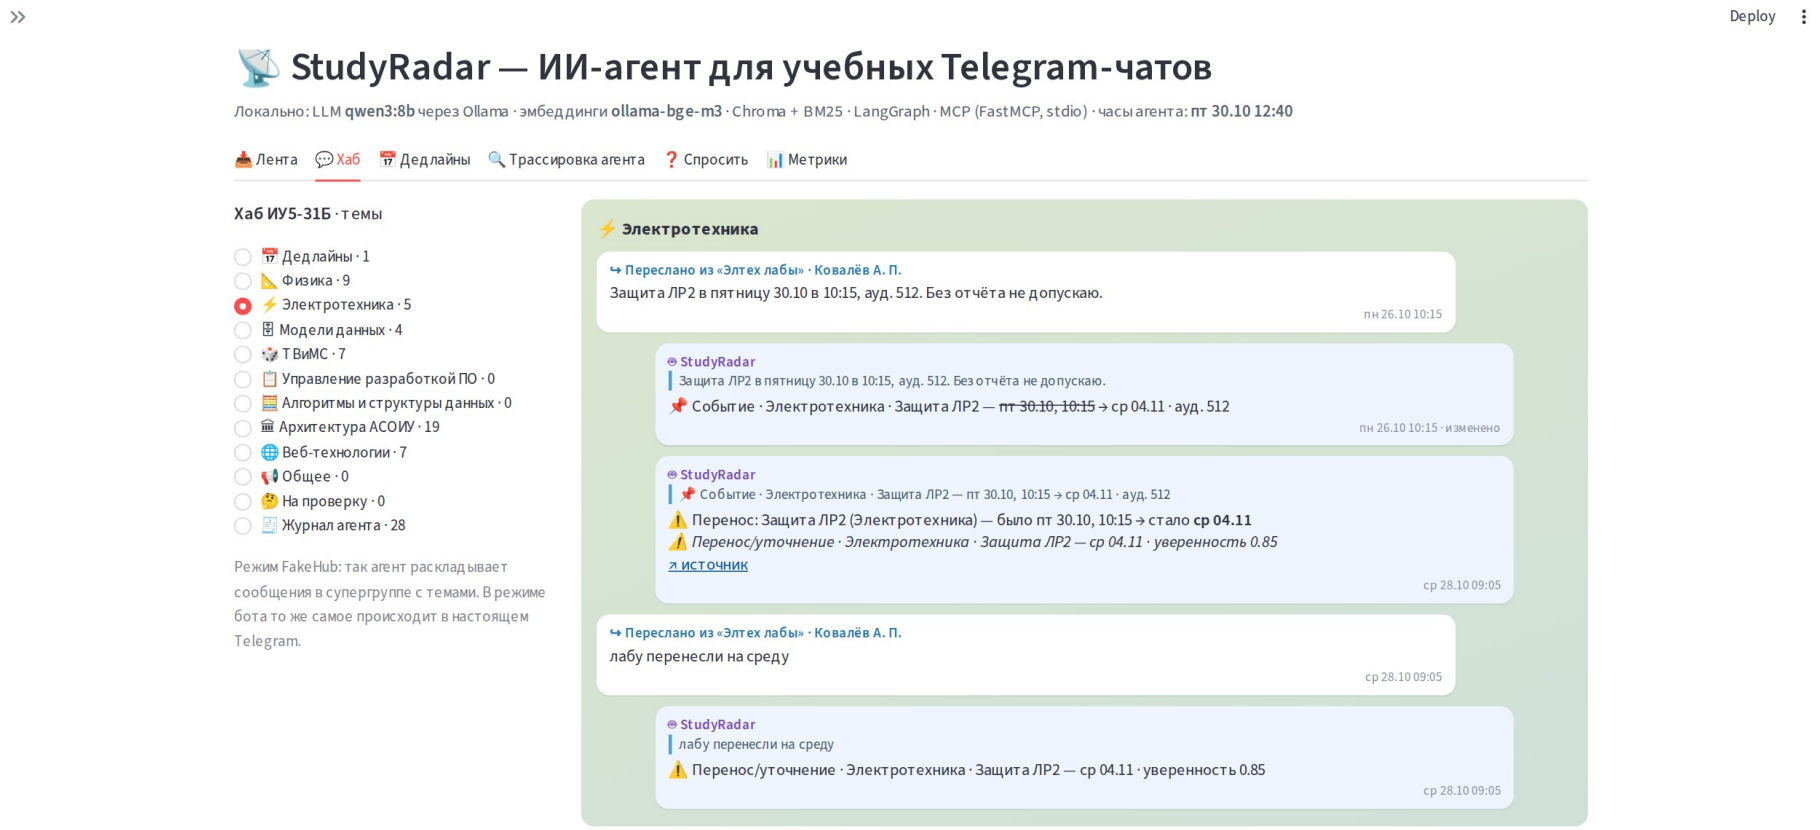
Экранная форма: чат-хаб и доска дедлайнов

Закреплённая доска, отсортированная по сроку; переносы — «было: ...»



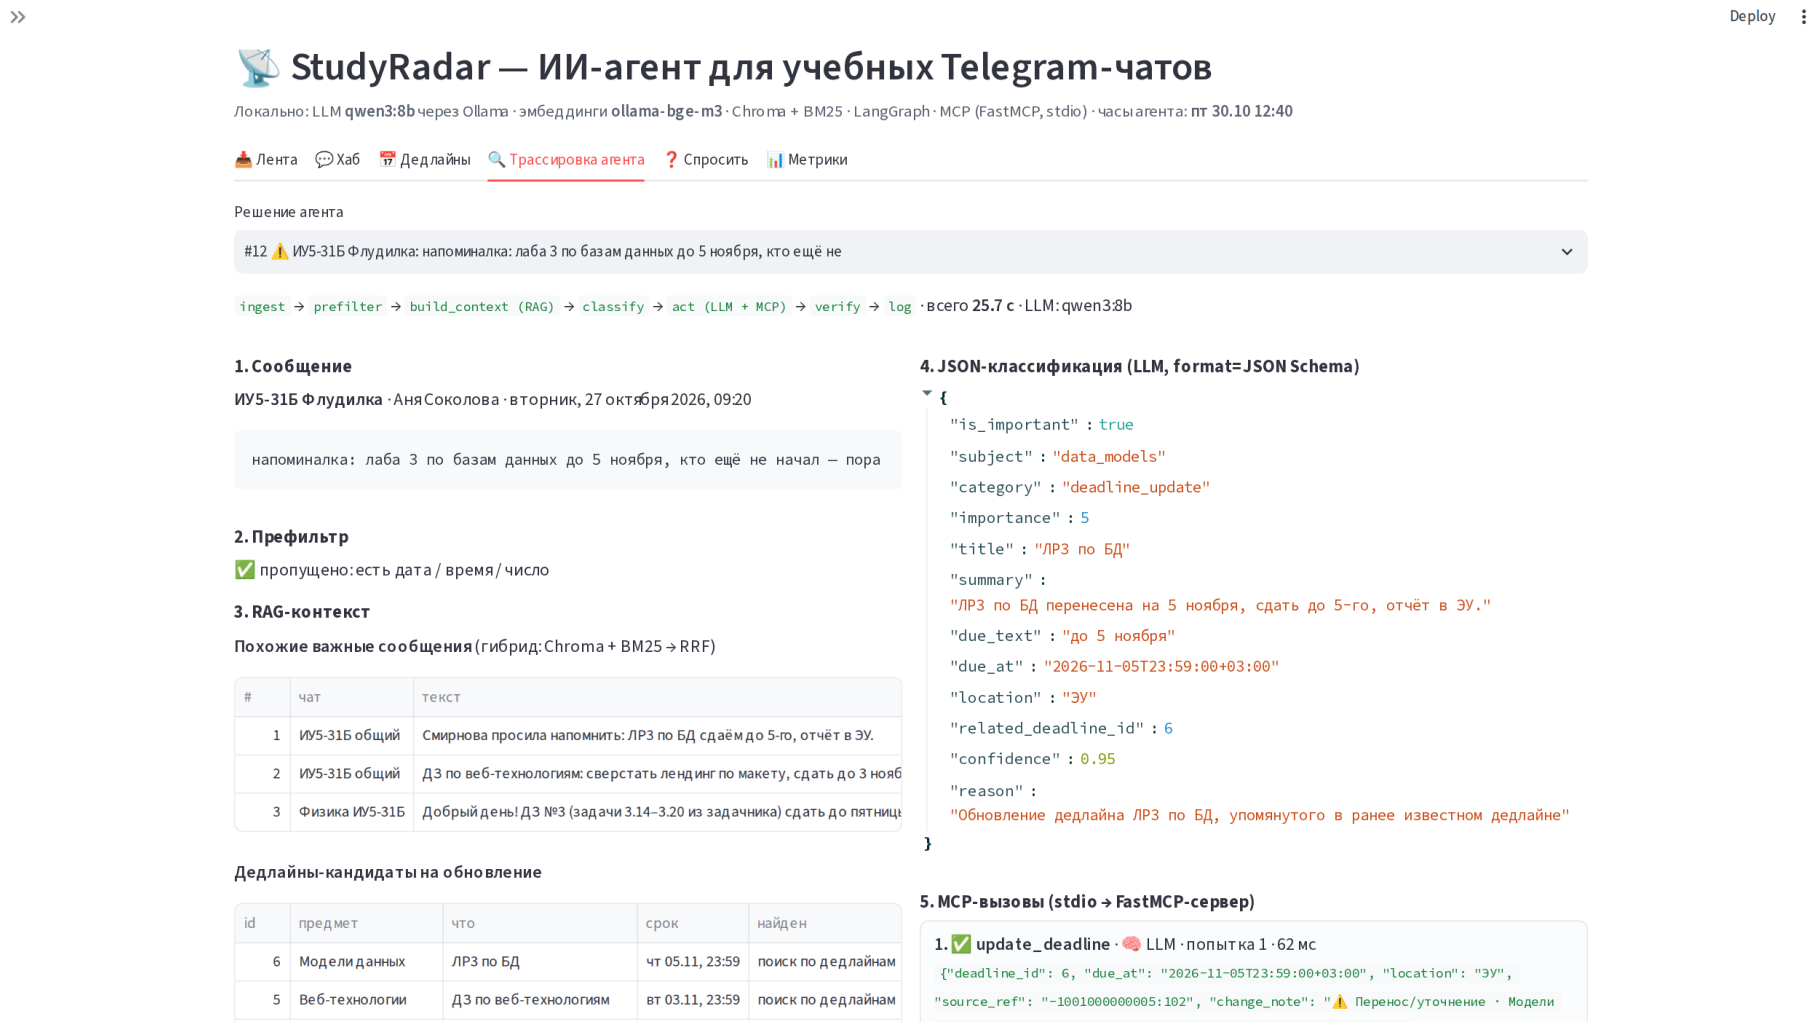
Экранная форма: тема предмета

Пересланное сообщение + пометка агента; при переносе старая дата зачёркнута



Экранная форма: трассировка агента (1/2)

Сообщение → префильтр → RAG-контекст → JSON-классификация



Экранная форма: трассировка агента (2/2)

LLM сама вызывает инструменты MCP-сервера (stdio) → verify

5. MCP-вызовы (stdio → FastMCP-сервер)

1. ✅ **update_deadline** · 🧠 LLM · попытка 1 · 62 мс


```
{"deadline_id": 6, "due_at": "2026-11-05T23:59:00+03:00", "location": "ЭУ",
"source_ref": "-1001000000005:102", "change_note": "⚠️ Перенос/уточнение · Модели
данных · ЛР3 по БД — чт 05.11, 23:59 · ЭУ · уверенность 0.95"}
```

→ {"ok": true, "id": 6, "changed": false, "message": "Изменений нет (источник учтён)"}

2. ✅ **forward_to_topic** · 🧠 LLM · попытка 1 · 20 мс


```
{"note": "⚠️ Перенос/уточнение · Модели данных · ЛР3 по БД — чт 05.11, 23:59 · ЭУ
· уверенность 0.95", "subject": "data_models", "source_chat_id": -1001000000005,
"message_ids": [102]}
```

→ {"ok": true, "topic": "🗄 Модели данных", "forwarded": 1, "note_id": 28}

3. ✅ **refresh_deadlines_board** · 🧠 LLM · попытка 1 · 31 мс


```
{}
```

→ {"ok": true, "pages": 1, "active_deadlines": 6}

6. Verify

✅ сообщение переслано в хаб
✅ дедлайн в БД со ссылкой на источник
✅ доска дедлайнов обновлена

Модуль 3 в действии

Сообщение «Чемпионат будет проходить в аудитории 501ю, 30 октября с 16:00» — уточнение известного события.

1. forward_to_topic — переслать в тему «Архитектура АСОИУ» с пометкой агента

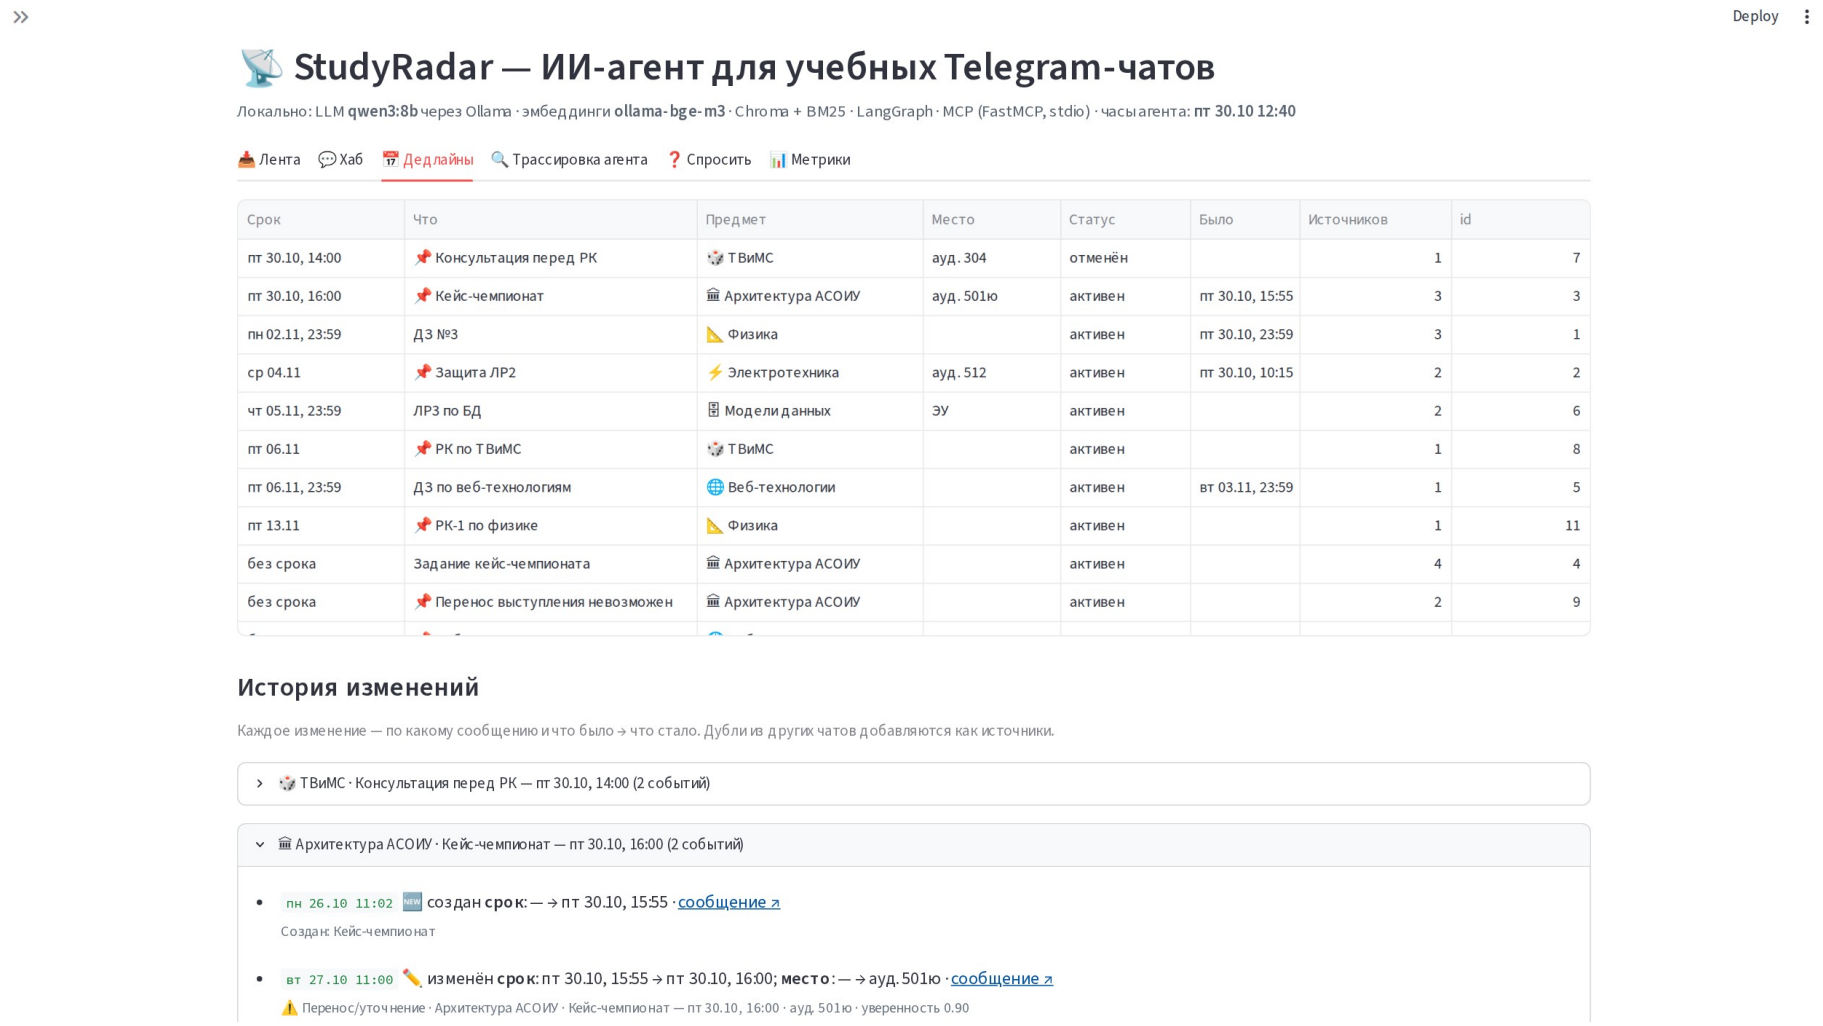
2. update_deadline — время 15:55 → 16:00, место → ауд. 501ю; история сохранена

3. refresh_deadlines_board — перерисовать закреплённую доску

Verify проверяет эффекты; если LLM ошиблась дважды — фолбэк через те же MCP-инструменты.

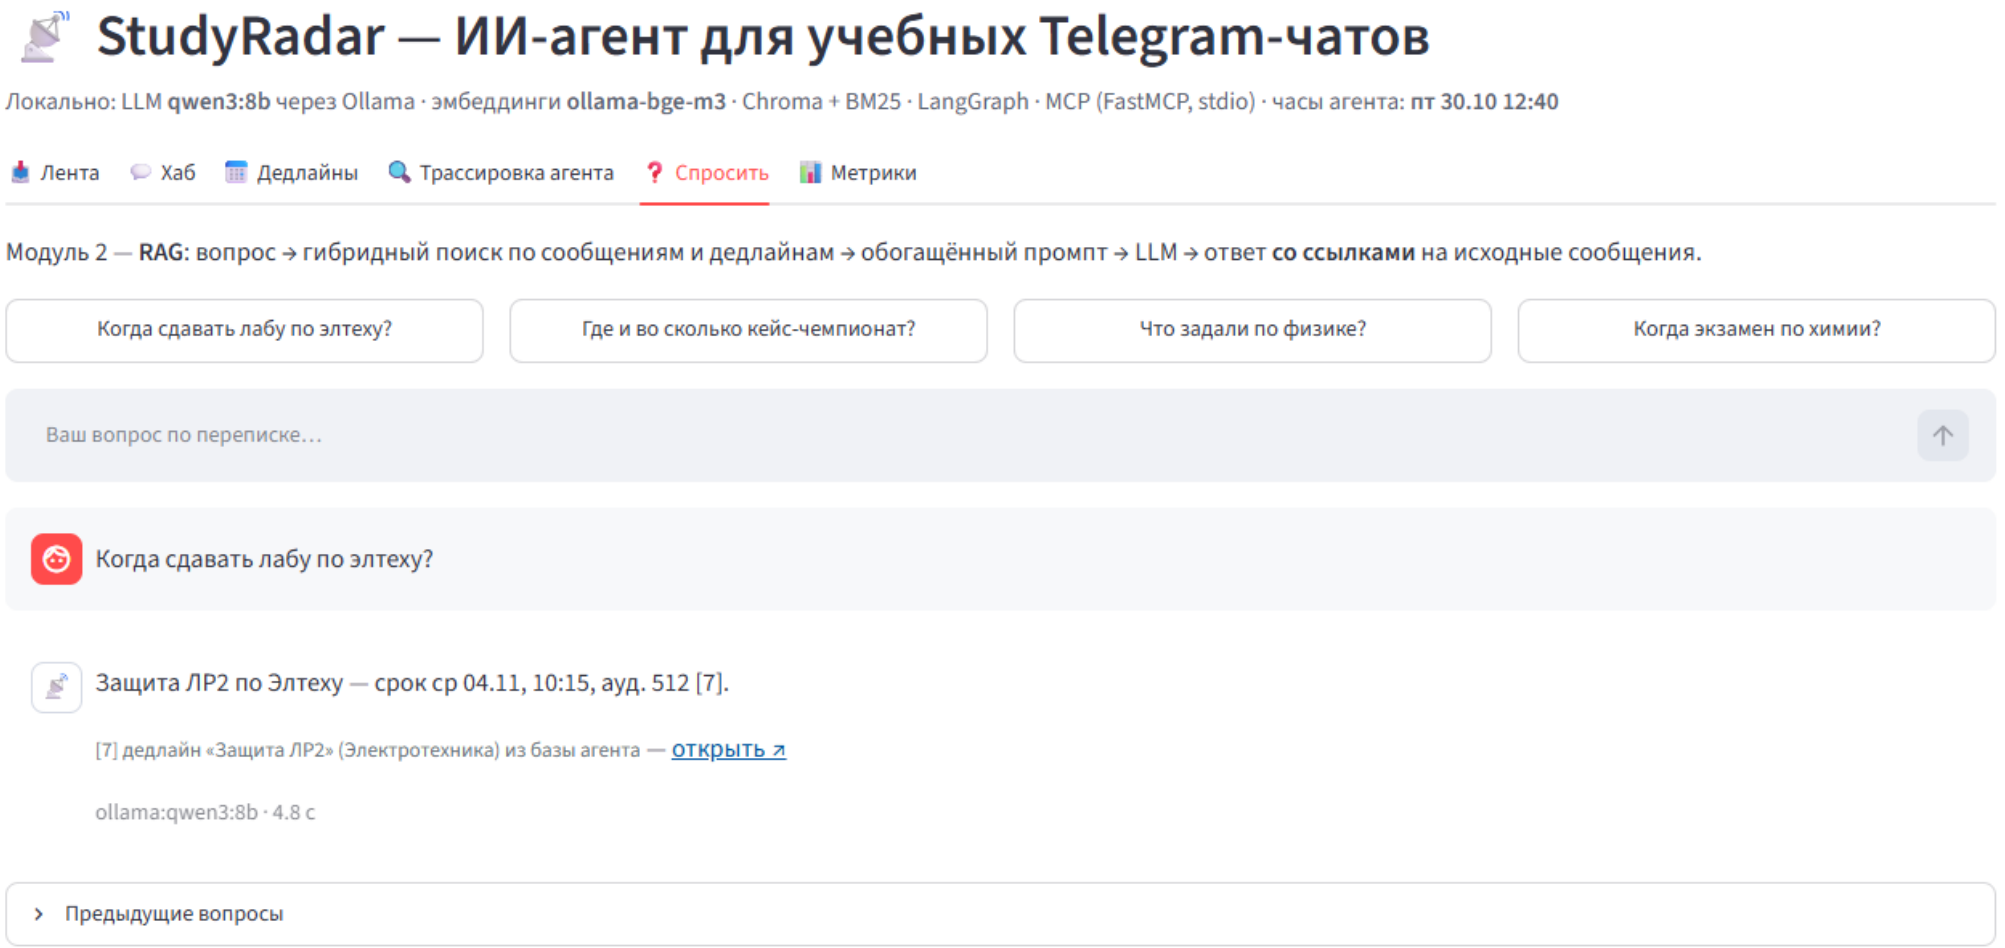
Экранная форма: дедлайны и история

Таблица по сроку и история изменений: было → стало, по какому сообщению



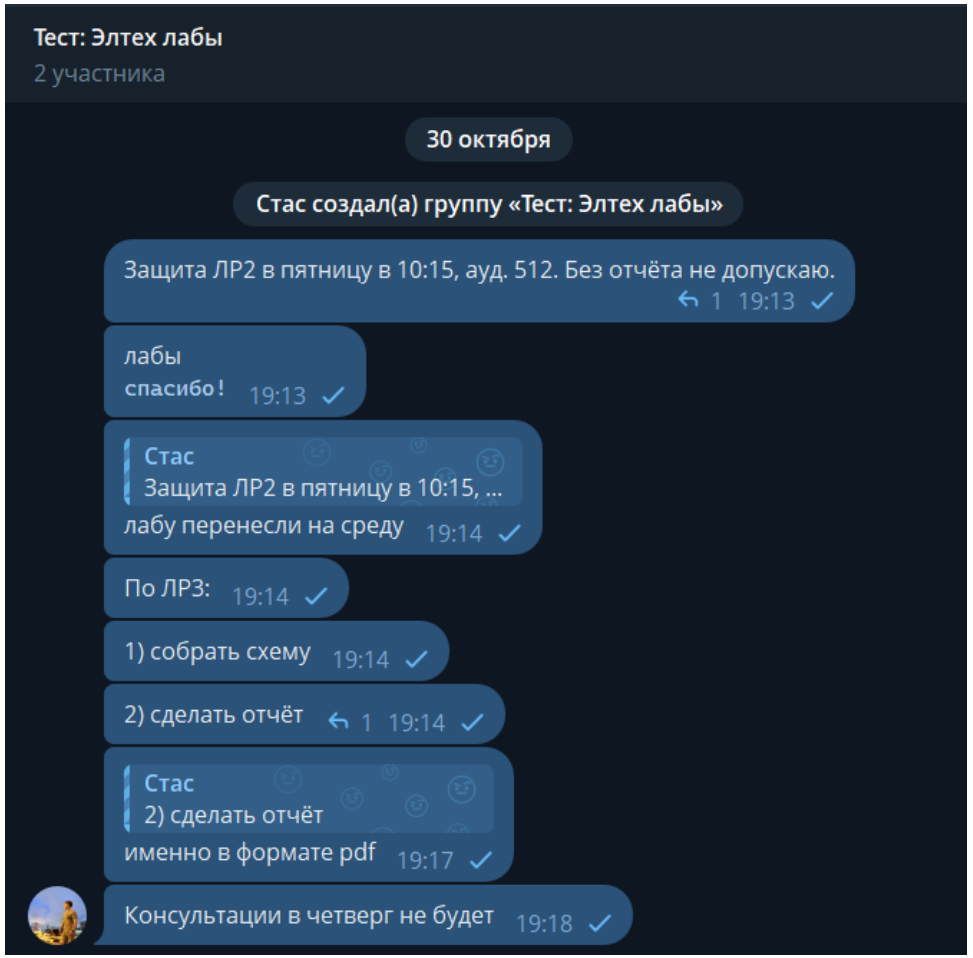
Экранная форма: вопрос по переписке (RAG)

Ответ со ссылками на исходные сообщения

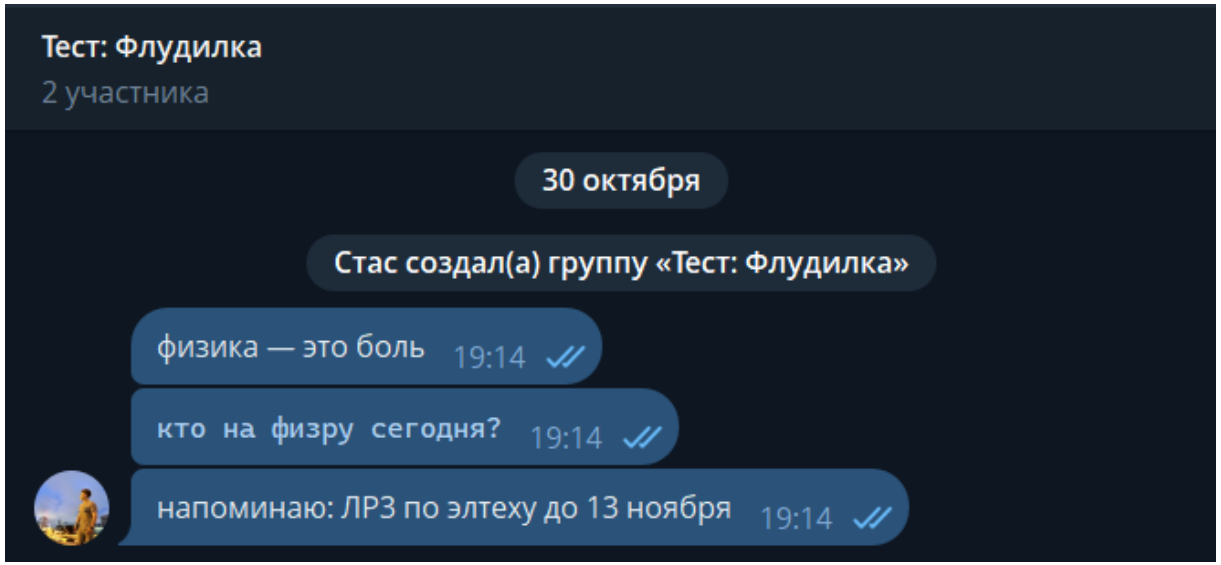


Telegram: учебные чаты-источники

Бот добавлен в группы и читает их как участник — новые и отредактированные сообщения



Чат «Тест: Элтех лабы»



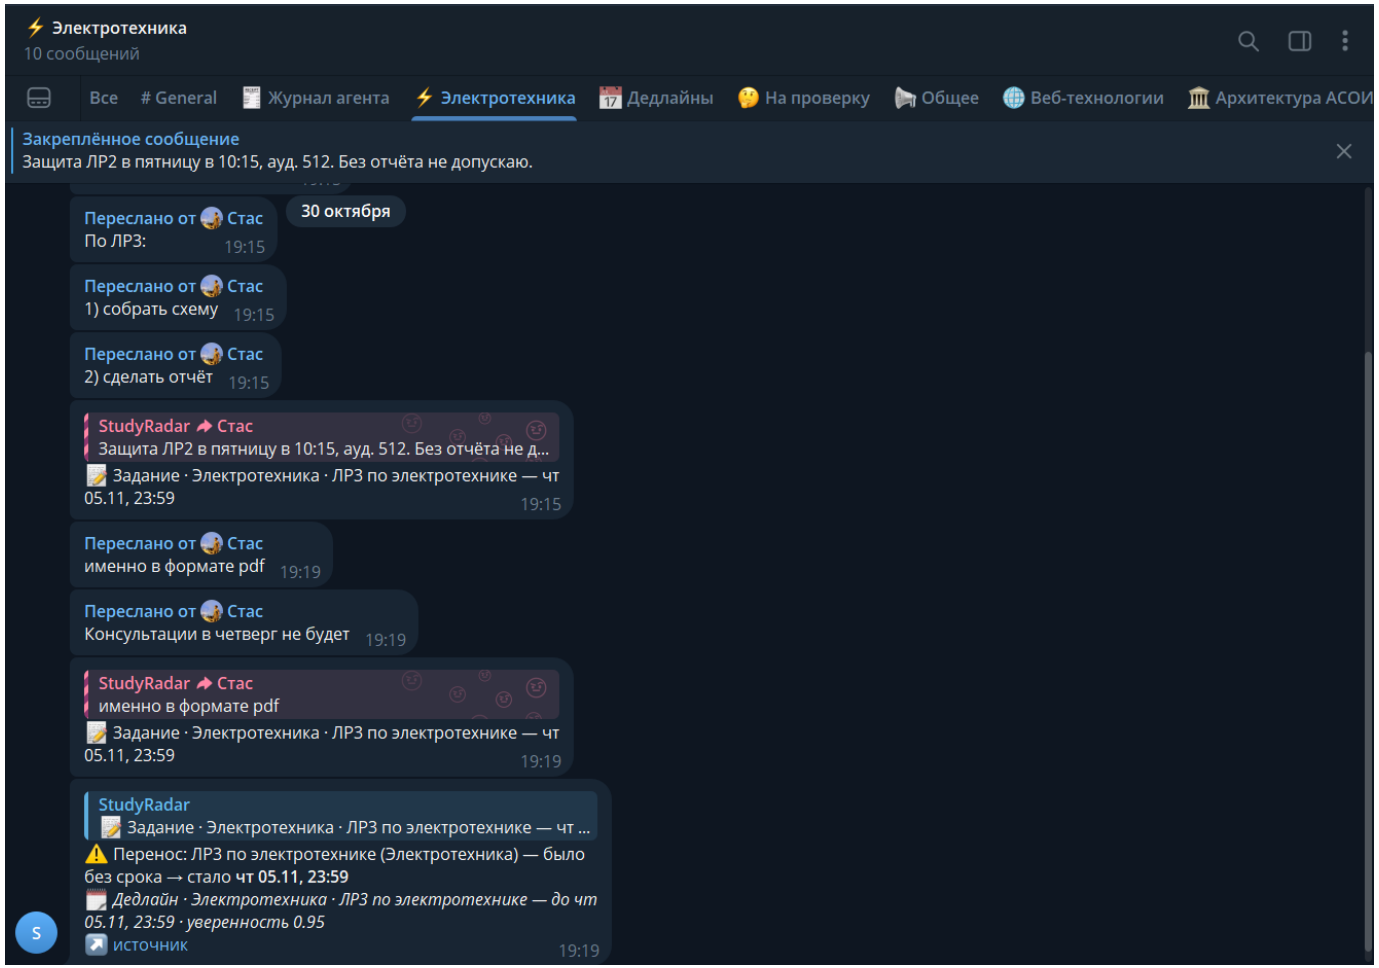
Чат «Тест: Флудилка»

1. **Важное вперемешку с болтовнёй**
   защита ЛР2, перенос ответом, «По ЛР3: 1) 2)», уточнение, отмена

2. **Шум и напоминание из другого чата**
   «физика — это боль», «кто на физру?» и та же ЛР3 во «Флудилке»

Telegram: тема предмета в чате-хабе

Хаб — супергруппа с темами; темы предметов и служебные темы бот создал сам по команде /sethub



Хаб → тема «⚡ Электротехника»

1. **Темы созданы ботом**
   предметы, 📅 Дедлайны, 🤔 На проверку, 🗒 Журнал агента

2. **Важное — в тему предмета**
   сообщения пересланы из чата-источника с автором

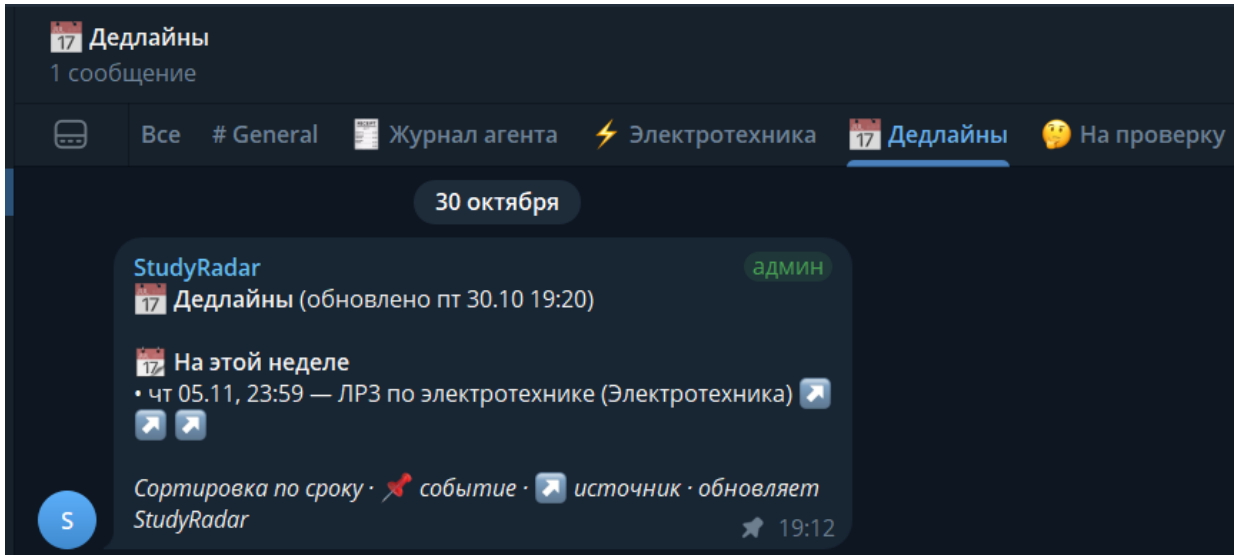
3. **Объявление закреплено**
   сверху темы — сообщение о защите ЛР2

4. **Пометка агента**
   категория · предмет · название · срок

5. **Изменение срока**
   ответ «⚠ Перенос: было → стало» с уверенностью модели и ссылкой на источник

Telegram: доска дедлайнов и вопросы по переписке

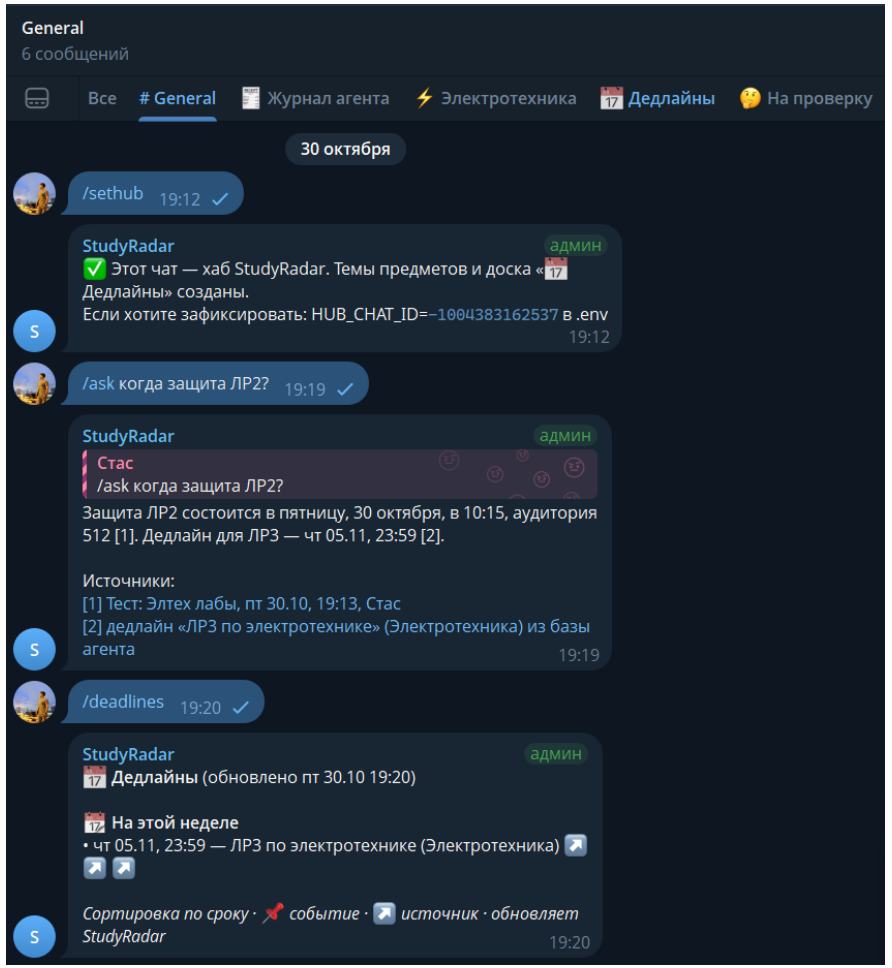
Закреплённая доска в теме «📅 Дедлайны» и команды /ask, /deadlines в хабе



Хаб → тема «📅 Дедлайны» (закреплённое сообщение)

1. **Одна доска вместо ленты**
   бот редактирует закреп при каждом изменении; сортировка по сроку, ↗ — источники

2. **/ask — Модуль 2 (RAG)**
   ответ по переписке со ссылками [1], [2] на сообщения и дедлайны из базы



Хаб → General: /ask и /deadlines

Результаты

80 размеченных постов (data/eval/labeled.jsonl) · бейзлайн — ключевые слова на тех же постах

Метрика	StudyRadar (LLM)	Ключевые слова
F1 важности	0.77	0.73
Precision / Recall	0.62 / 1.00	0.62 / 0.87
Точность предмета	0.96	0.43
Точность категории	0.87	0.74
Точность даты (день)	1.00	0.89

ollama:qwen3:8b

Linux 6.6.87.2-microsoft-standard-WSL2 · 13th Gen Intel(R) Core(TM) i7-13620H · 12 ГБ RAM · NVIDIA GeForce RTX 4060 Laptop GPU, 8188 MiB

MCP-действия без фолбэка: 100%

Корректных вызовов инструментов LLM: 94%

Средняя задержка: 5.5 с на пост

Дедлайнов с несколькими источниками (дубли объединены): 4

Сложные случаи (верно)	ответ на вопрос	серия сообщений (склейка)	дубль из другого чата	«физра» ≠ физика	мемы	сарказм	предмет упомянут, но это шум	названия команд
StudyRadar	5 из 5	2 из 2	1 из 1	1 из 1	1 из 1	1 из 1	2 из 2	3 из 3
Ключевые слова	1 из 5	0 из 2	1 из 1	0 из 1	0 из 1	0 из 1	0 из 2	2 из 3

Как запустить и где код

Локально, на обычном ноутбуке

Демо за 10 минут

```
ollama pull qwen3:8b && ollama pull bge-m3
make setup && make doctor
make simulate      # демо-сценарий настоящей моделью
make ui            # http://localhost:8501
make bot           # режим Telegram-бота
```

8 ГБ RAM: LLM_MODEL=qwen3:4b в .env

Telegram через VPN: TELEGRAM_PROXY=http://127.0.0.1:<порт> в .env

Репозиторий

https://github.com/winlast/TG_Agent_champ

README → «Как запустить демо за 10 минут»

Спасибо за внимание!

Готовы ответить на вопросы

https://github.com/winlast/TG_Agent_champ